OPi AI Studio 配置记录 - Ubuntu（310P 驱动 + MindIE + Daemon + curl 调用接口）

上一篇在 Windows 下完成了 OPi AI Studio 的基础配置，但遇到了影响使用的报错。因此这次切到 Ubuntu 22.04 + Linux 5.15，重新整理一套可复现的部署流程。

一、目标环境与下载准备

310P NPU 驱动包当前适配的推荐系统为 Ubuntu 22.04，内核版本为 Linux 5.15。

Ubuntu 镜像（`ubuntu-22.04.5-desktop-amd64.iso`）可从以下地址下载：

- https://mirrors.ustc.edu.cn/ubuntu-releases/22.04.5/ubuntu-22.04.5-desktop-amd64.iso
- https://mirrors.huaweicloud.com/ubuntu-releases/22.04.5/ubuntu-22.04.5-desktop-amd64.iso

二、切换并固定 Linux 5.15 内核

1) 检查当前内核

```
uname -r
```

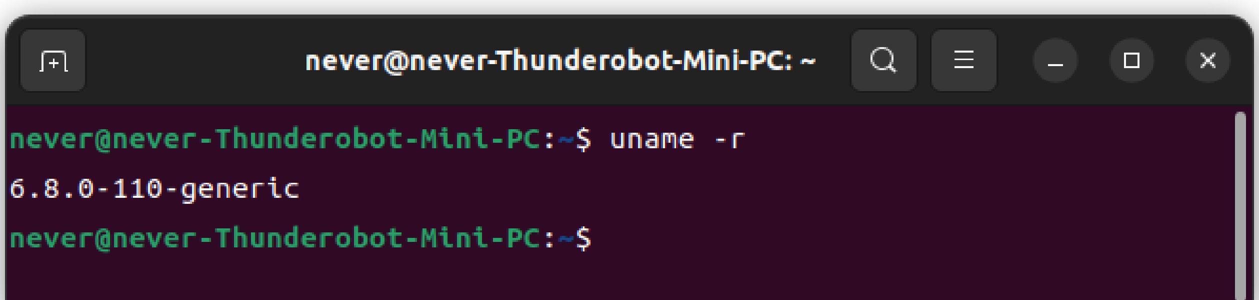

2) 安装 5.15.0-126 内核与头文件

```
sudo apt update
sudo apt install -y linux-image-5.15.0-126-generic linux-modules-extra-5.15.0-126-generic
sudo apt install -y linux-headers-5.15.0-126 linux-headers-5.15.0-126-generic
```

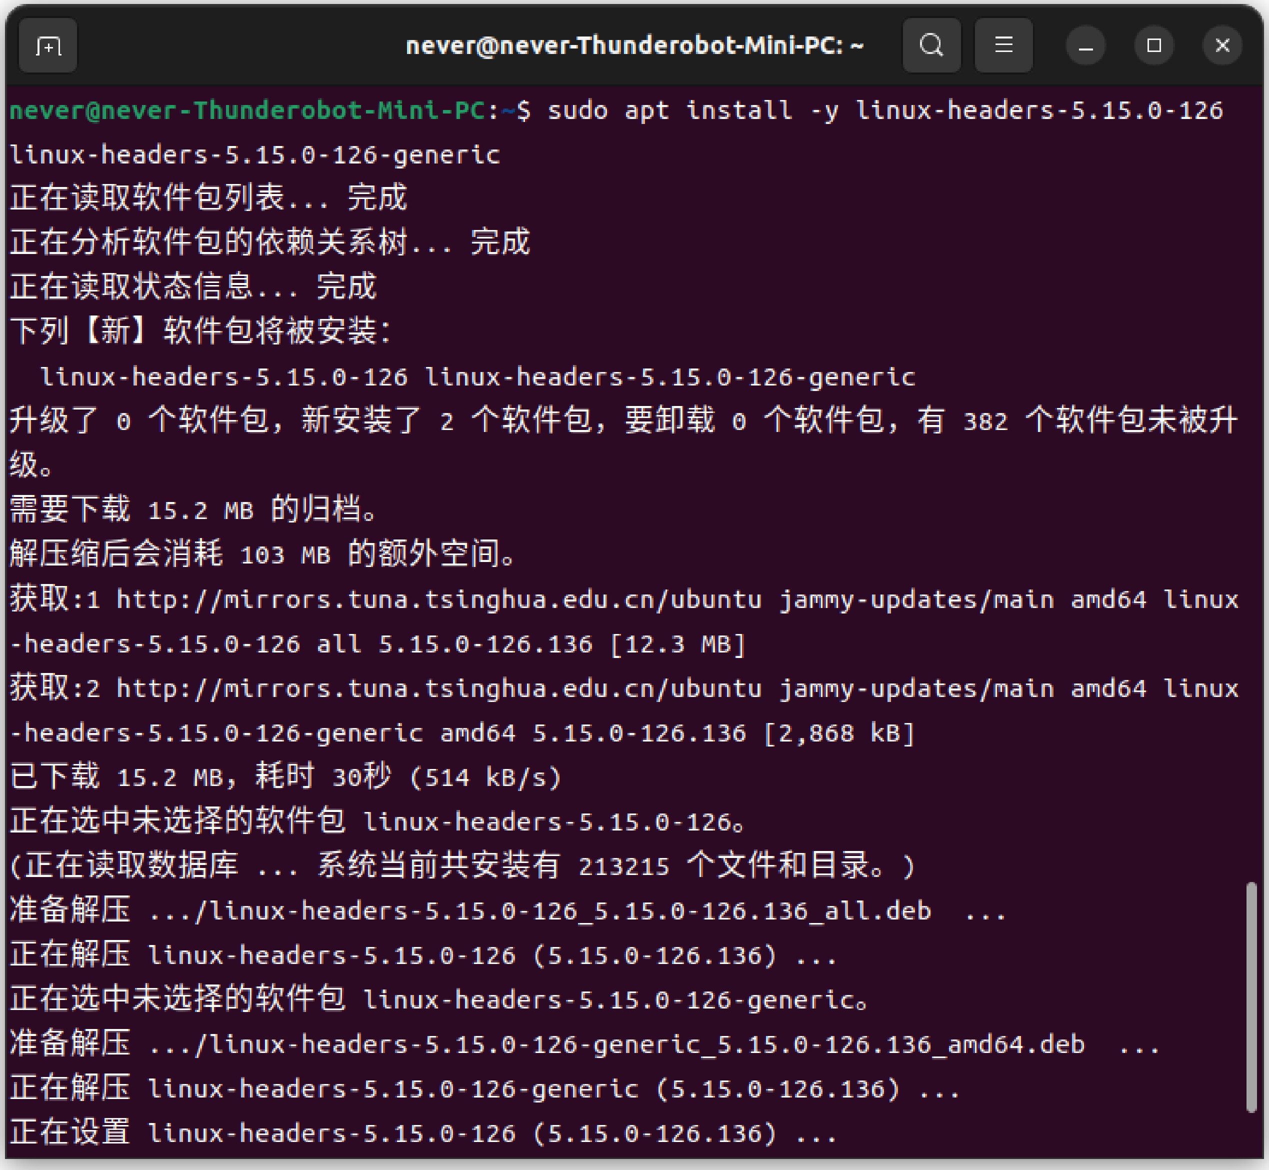

```
never@never-Thunderobot-Mini-PC: ~
never@never-Thunderobot-Mini-PC:~$ sudo apt install -y linux-headers-5.15.0-126
linux-headers-5.15.0-126-generic
正在读取软件包列表... 完成
正在分析软件包的依赖关系树... 完成
正在读取状态信息... 完成
下列【新】软件包将被安装：
  linux-headers-5.15.0-126 linux-headers-5.15.0-126-generic
升级了 0 个软件包，新安装了 2 个软件包，要卸载 0 个软件包，有 382 个软件包未被升
级。
需要下载 15.2 MB 的归档。
解压缩后会消耗 103 MB 的额外空间。
获取:1 http://mirrors.tuna.tsinghua.edu.cn/ubuntu jammy-updates/main amd64 linux
-headers-5.15.0-126 all 5.15.0-126.136 [12.3 MB]
获取:2 http://mirrors.tuna.tsinghua.edu.cn/ubuntu jammy-updates/main amd64 linux
-headers-5.15.0-126-generic amd64 5.15.0-126.136 [2,868 kB]
已下载 15.2 MB，耗时 30秒 (514 kB/s)
正在选中未选择的软件包 linux-headers-5.15.0-126。
(正在读取数据库 ... 系统当前共安装有 213215 个文件和目录。)
准备解压 .../linux-headers-5.15.0-126_5.15.0-126.136_all.deb  ...
正在解压 linux-headers-5.15.0-126 (5.15.0-126.136) ...
正在选中未选择的软件包 linux-headers-5.15.0-126-generic。
准备解压 .../linux-headers-5.15.0-126-generic_5.15.0-126.136_amd64.deb  ...
正在解压 linux-headers-5.15.0-126-generic (5.15.0-126.136) ...
正在设置 linux-headers-5.15.0-126 (5.15.0-126.136) ...
```

3) 修改 GRUB 默认启动项

先安装编辑器：

```
sudo apt install -y vim
```

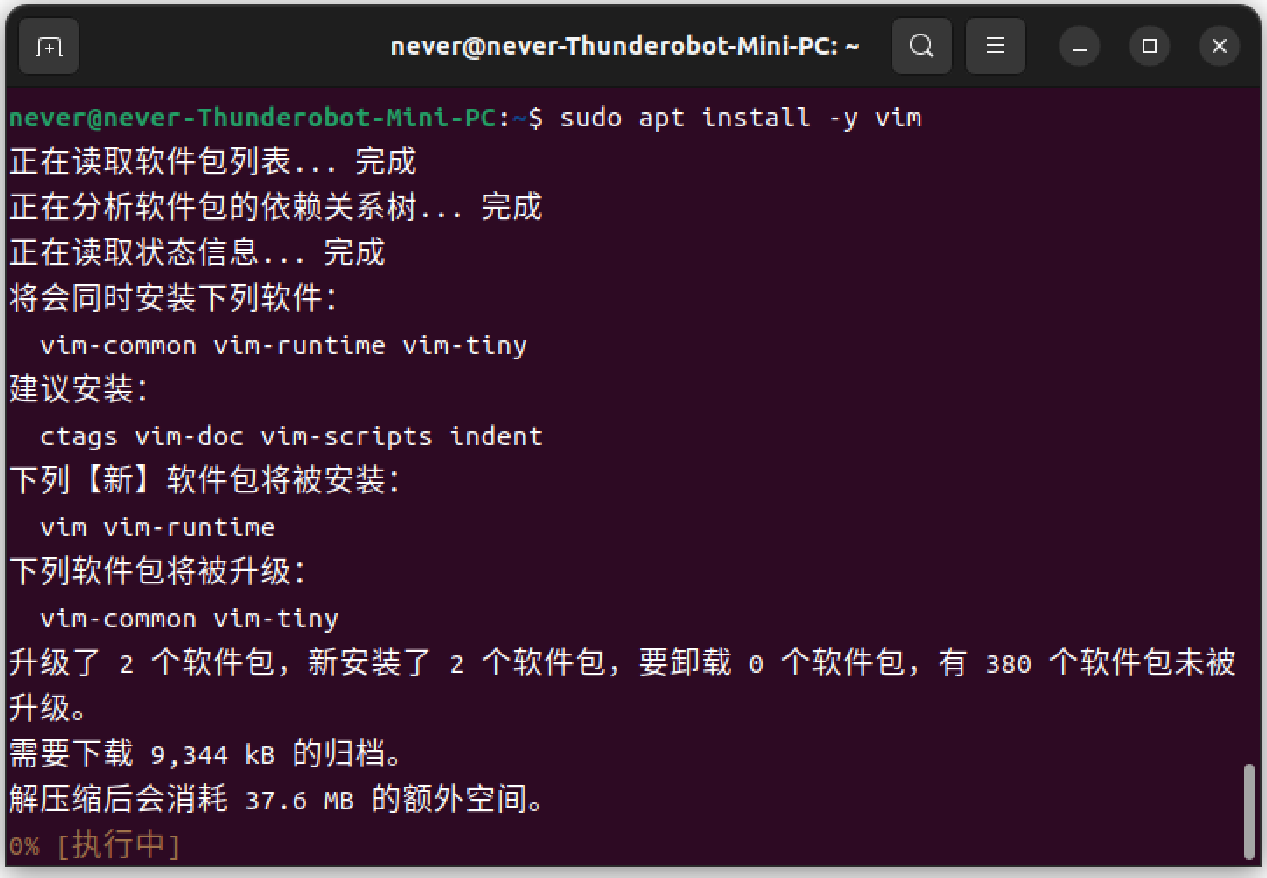

编辑 GRUB：

```
sudo vim /etc/default/grub
```

将 `GRUB_DEFAULT` 指向 5.15 内核项：

```
GRUB_DEFAULT="Advanced options for Ubuntu>Ubuntu, with Linux 5.15.0-126-generic"
```

如果推理期间 NPU 利用率和显存占用有明显变化，说明任务已正确落到设备侧。加载进度跑到 100% 后，通常就会继续进入模型推理阶段：

```
# If you change this file, run 'update-grub' afterwards to update
# /boot/grub/grub.cfg.
# For full documentation of the options in this file, see:
#   info -f grub -n 'Simple configuration'

GRUB_DEFAULT="Advanced options for Ubuntu>Ubuntu,with Linux 5.15.0-126-generic"
GRUB_TIMEOUT_STYLE=hidden
GRUB_TIMEOUT=10
GRUB_DISTRIBUTOR=`lsb_release -i -s 2> /dev/null || echo Debian`
GRUB_CMDLINE_LINUX_DEFAULT="quiet splash modprobe.blacklist=thunderbolt"
GRUB_CMDLINE_LINUX=""

# Uncomment to enable BadRAM filtering, modify to suit your needs
# This works with Linux (no patch required) and with any kernel that obtains
# the memory map information from GRUB (GNU Mach, kernel of FreeBSD ...)
#GRUB_BADRAM="0x01234567,0xfefefefe,0x89abcdef,0xefefefef"

# Uncomment to disable graphical terminal (grub-pc only)
#GRUB_TERMINAL=console

:wq
```

更新并重启:

```
sudo update-grub
sudo reboot
```

```
never@never-Thunderobot-Mini-PC: ~
never@never-Thunderobot-Mini-PC:~$ sudo update-grub
Sourcing file `/etc/default/grub'
Sourcing file `/etc/default/grub.d/init-select.cfg'
Generating grub configuration file ...
Found linux image: /boot/vmlinuz-6.8.0-110-generic
Found initrd image: /boot/initrd.img-6.8.0-110-generic
Found linux image: /boot/vmlinuz-6.8.0-40-generic
Found initrd image: /boot/initrd.img-6.8.0-40-generic
Found linux image: /boot/vmlinuz-5.15.0-126-generic
Found initrd image: /boot/initrd.img-5.15.0-126-generic
Memtest86+ needs a 16-bit boot, that is not available on EFI, exiting
Warning: os-prober will be executed to detect other bootable partitions.
Its output will be used to detect bootable binaries on them and create new boot ent
ries.
Found Windows Boot Manager on /dev/nvme0n1p2@/EFI/Microsoft/Boot/bootmgfw.efi
Adding boot menu entry for UEFI Firmware Settings ...
done
never@never-Thunderobot-Mini-PC:~$
```

重启后再次确认：

```
uname -r
```

预期输出： `5.15.0-126-generic`

```
never@never-Thunderobot-Mini-PC: ~
never@never-Thunderobot-Mini-PC:~$ uname -r
5.15.0-126-generic
never@never-Thunderobot-Mini-PC:~$
```

4) 可选：USB4/雷电 4 机器禁用 thunderbolt 模块

如果主机使用 USB4 或雷电 4 口，连接 OPi AI Studio 启动时可能出现 PCIe 相关错误，可追加以下配置：

```
sudo vim /etc/default/grub
```

```
GRUB_CMDLINE_LINUX_DEFAULT="quiet splash modprobe.blacklist=thunderbolt"
```

```
sudo update-grub
sudo reboot
```

三、检查硬件识别

系统启动后等待片刻，执行：

```
lspci
```

若能看到 ASMedia 相关信息和 OPi AI Studio PCIe 设备，则链路正常。

注意：和 Windows 场景相同，建议先给 OPi AI Studio 上电并连接，再启动电脑；反过来可能导致设备识别异常。

四、安装基础依赖

```
sudo apt update
sudo apt install -y dkms net-tools gcc make cmake git pigz pciutils vim dos2unix unrar
```

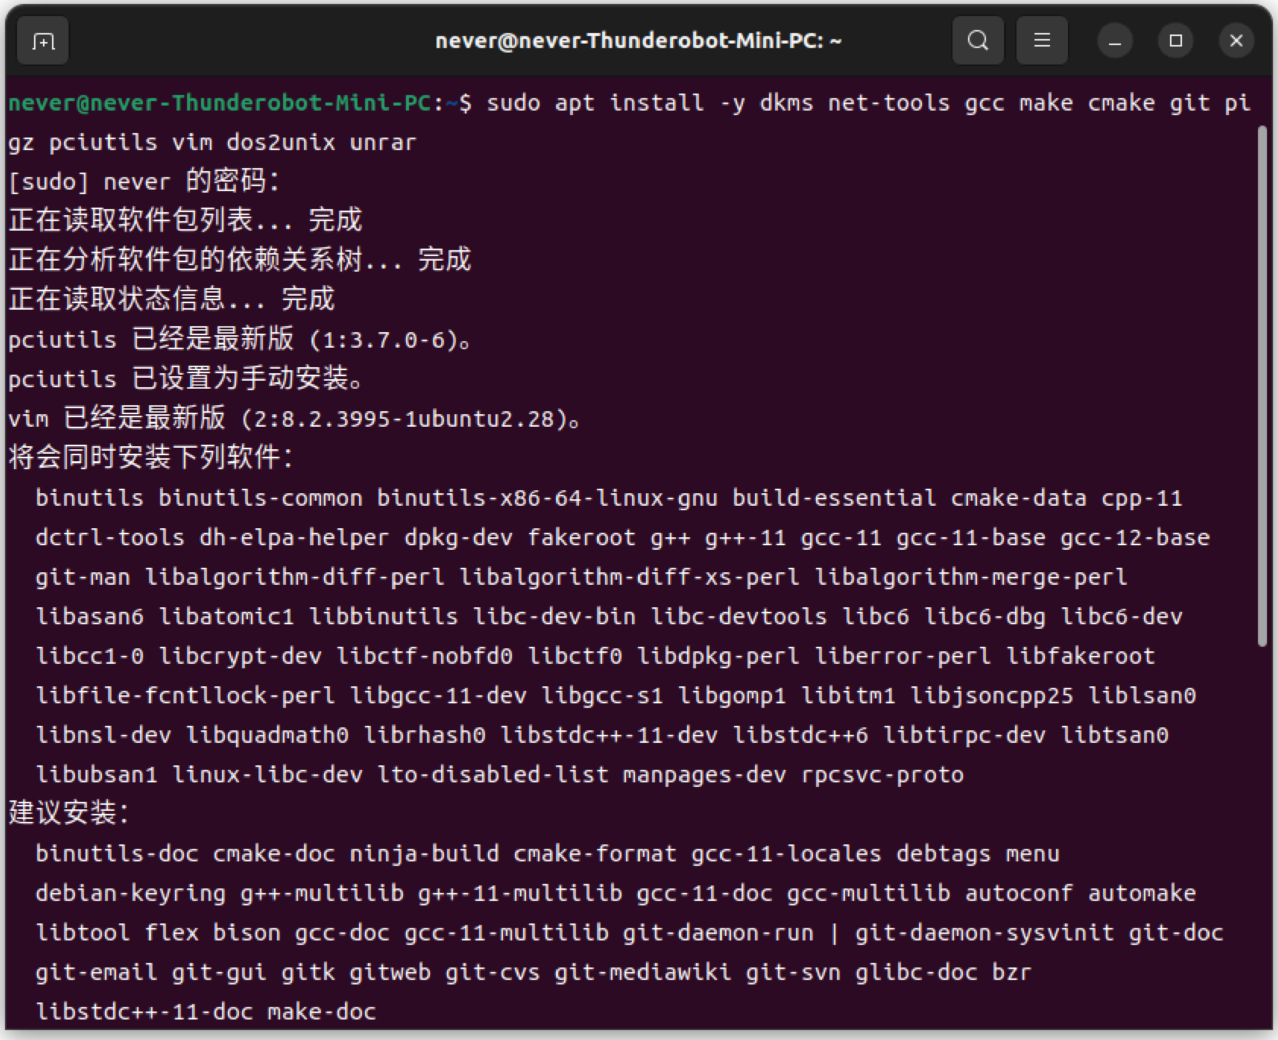

五、安装 310P NPU 驱动与固件

1) 安装驱动

驱动包：`Ascend-hdk-310p-npu-driver_24.1.t29_linux-x86-64-opiaistudo-20250212.run`

下载地址：https://pan.baidu.com/s/1b1hkpebtRXxawnoKQSV--Q?pwd=2m6f

赋予执行权限：

```
chmod +x Ascend-hdk-310p-npu-driver_24.1.t29_linux-x86-64-opiaistudo-20250212.run
```

安装（将 `test` 替换为实际普通用户名/组名）：

```
sudo ./Ascend-hdk-310p-npu-driver_24.1.t29_linux-x86-64-opiaistudo-20250212.run \
    --full --install-username=test --install-usergroup=test --install-for-all
```

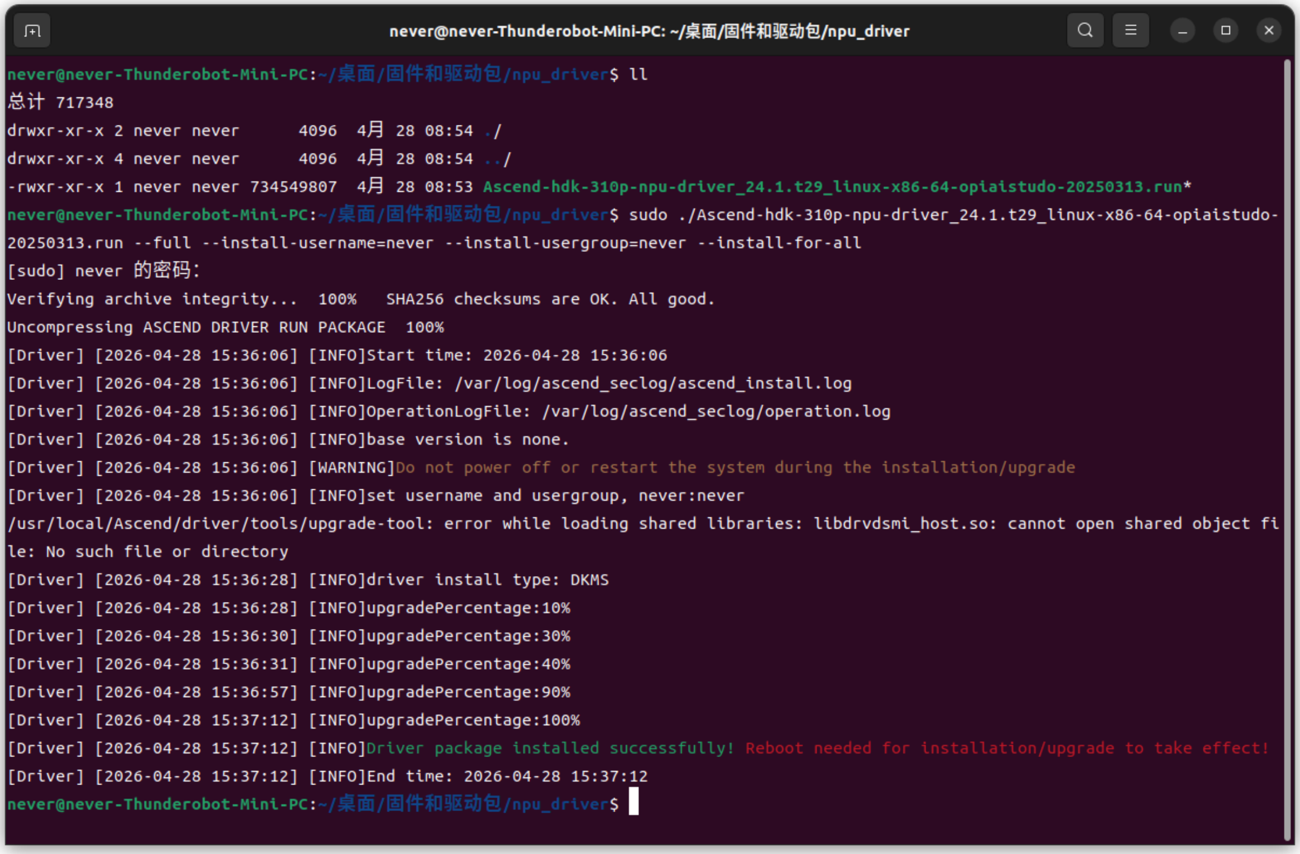

重启并验证:

```
sudo reboot
npu-smi info
```

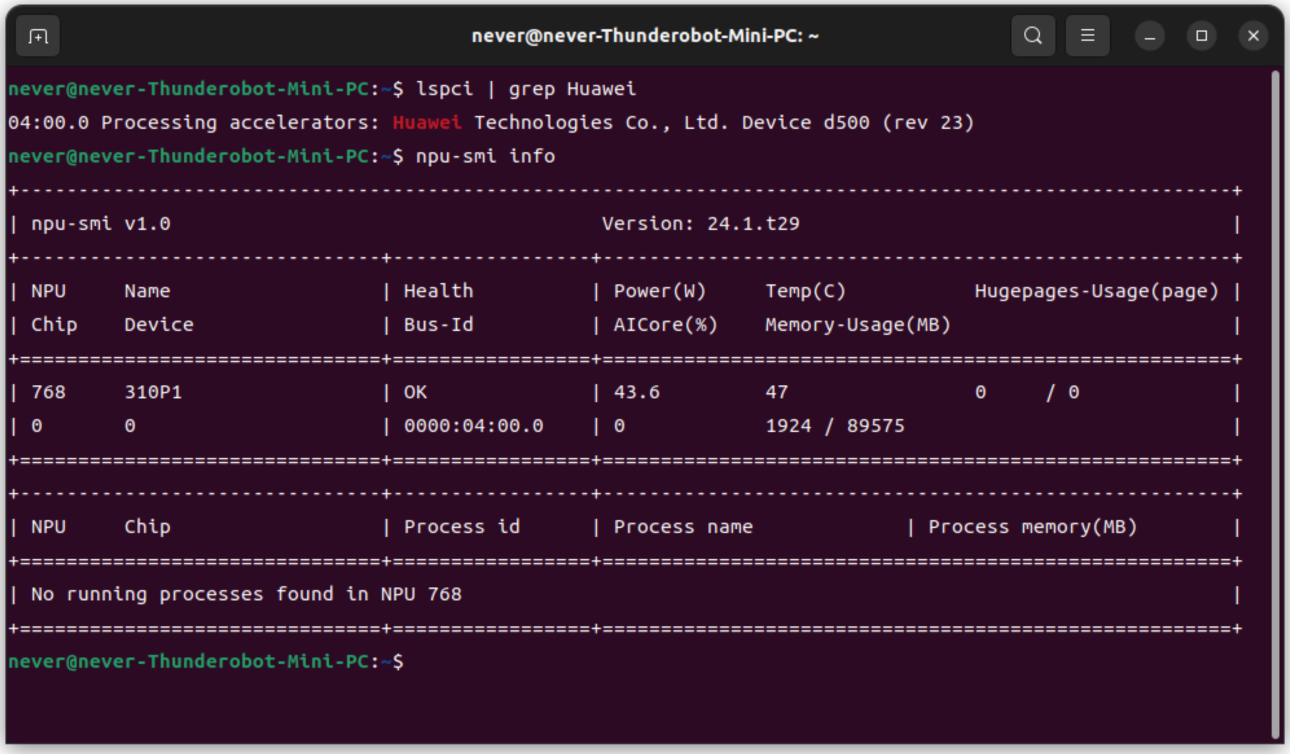

2) 安装固件

固件包：`Ascend-hdk-310p-npu-firmware_7.6.t7.0.b052-opiaistudio-20250311.run`

```
chmod +x Ascend-hdk-310p-npu-firmware_7.6.t7.0.b052-opiaistudio-20250311.run
sudo ./Ascend-hdk-310p-npu-firmware_7.6.t7.0.b052-opiaistudio-20250311.run --full
```

六、安装 Docker 与 MindIE 镜像

1) 安装 Docker

```
sudo apt install -y docker.io
```

切换 root：

```
sudo -i
```

2) 拉取 MindIE 镜像

```
docker pull --platform=amd64 swr.cn-south-1.myhuaweicloud.com/ascendhub/mindie:3.0.0-300I-
```

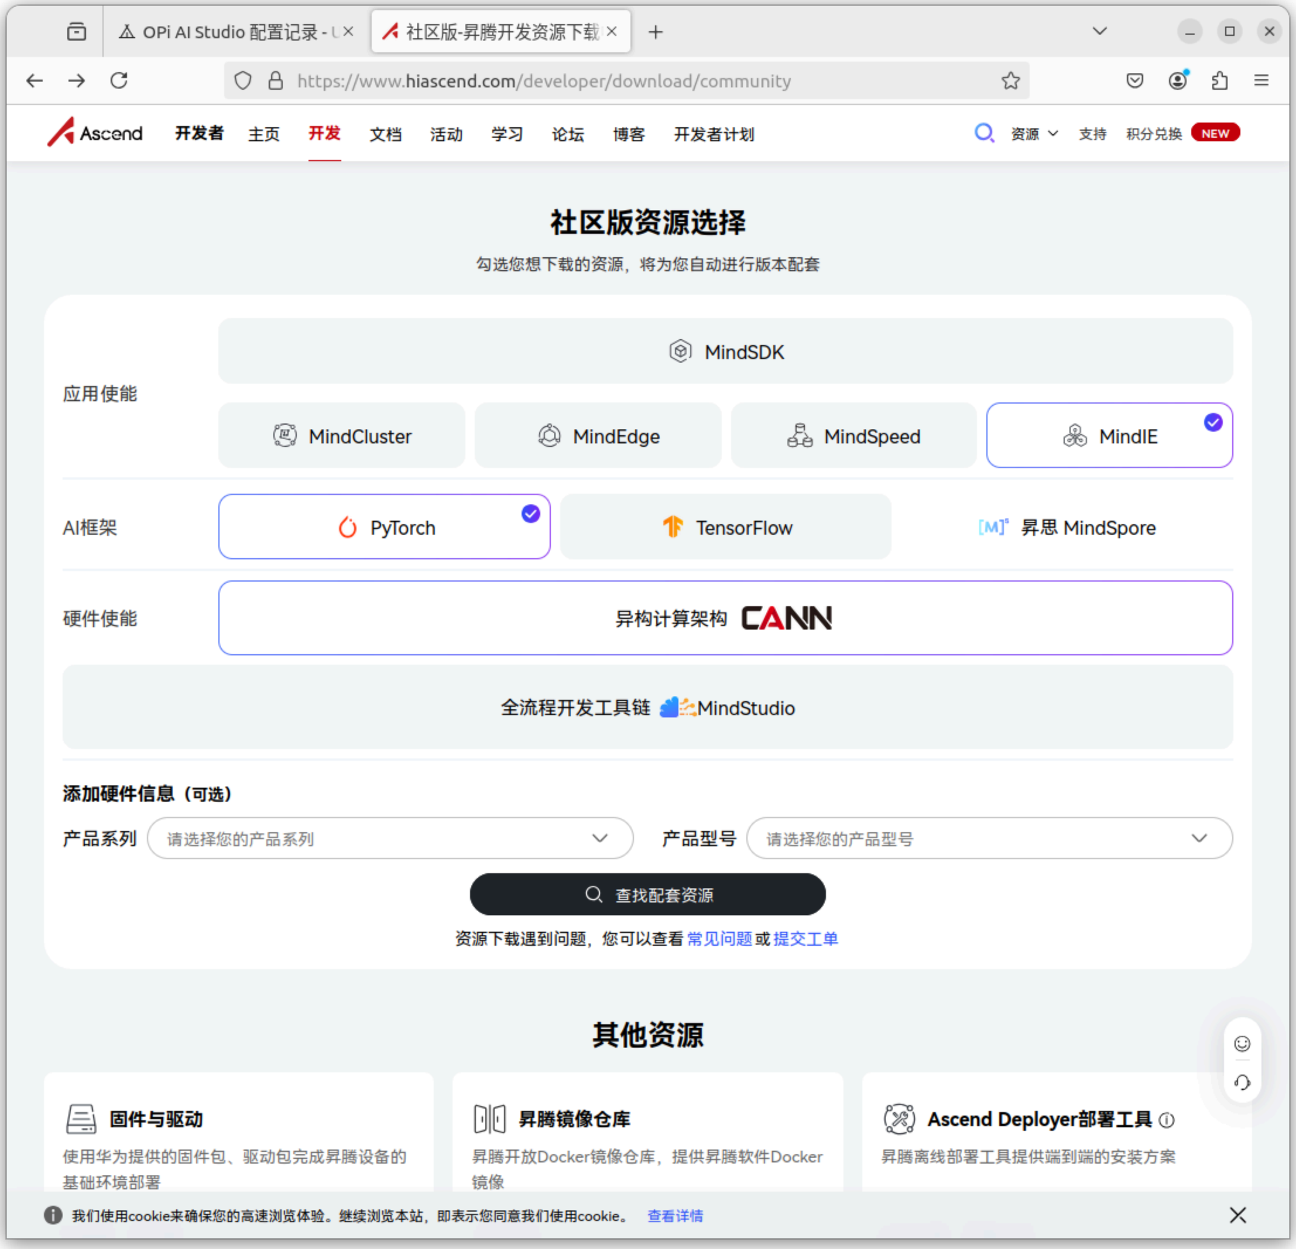
OPi AI Studio 配置记录 - ...
社区版-昇腾开发资源下载
https://www.hiascend.com/developer/download/community
Ascend 开发者 主页 开发 文档 活动 学习 论坛 博客 开发者计划
资源 支持 积分兑换 NEW
社区版资源选择
勾选您想下载的资源，将为您自动进行版本配套
应用使能
MindSDK
MindCluster
MindEdge
MindSpeed
MindIE
AI框架
PyTorch
TensorFlow
昇思 MindSpore
硬件使能
异构计算架构 CANN
全流程开发工具链 MindStudio
添加硬件信息（可选）
产品系列
请选择您的产品系列
产品型号
请选择您的产品型号
查找配套资源
资源下载遇到问题，您可以查看 常见问题 或 提交工单
其他资源
固件与驱动
使用华为提供的固件包、驱动包完成昇腾设备的基础环境部署
昇腾镜像仓库
昇腾开放Docker镜像仓库，提供昇腾软件Docker镜像
Ascend Deployer部署工具
昇腾离线部署工具提供端到端的安装方案
我们使用cookie来确保您的高速浏览体验。继续浏览本站，即表示您同意我们使用cookie。 查看详情

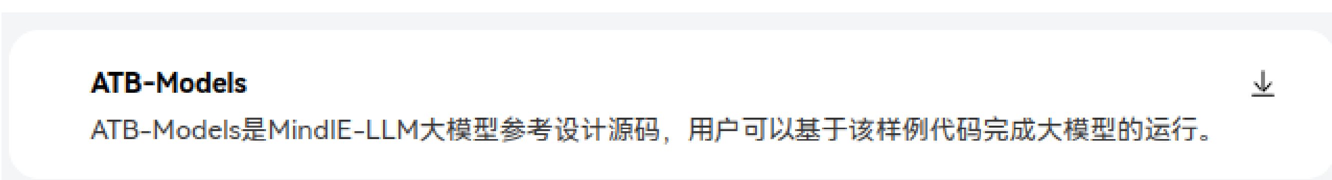
ATB-Models
ATB-Models是MindIE-LLM大模型参考设计源码，用户可以基于该样例代码完成大模型的运行。

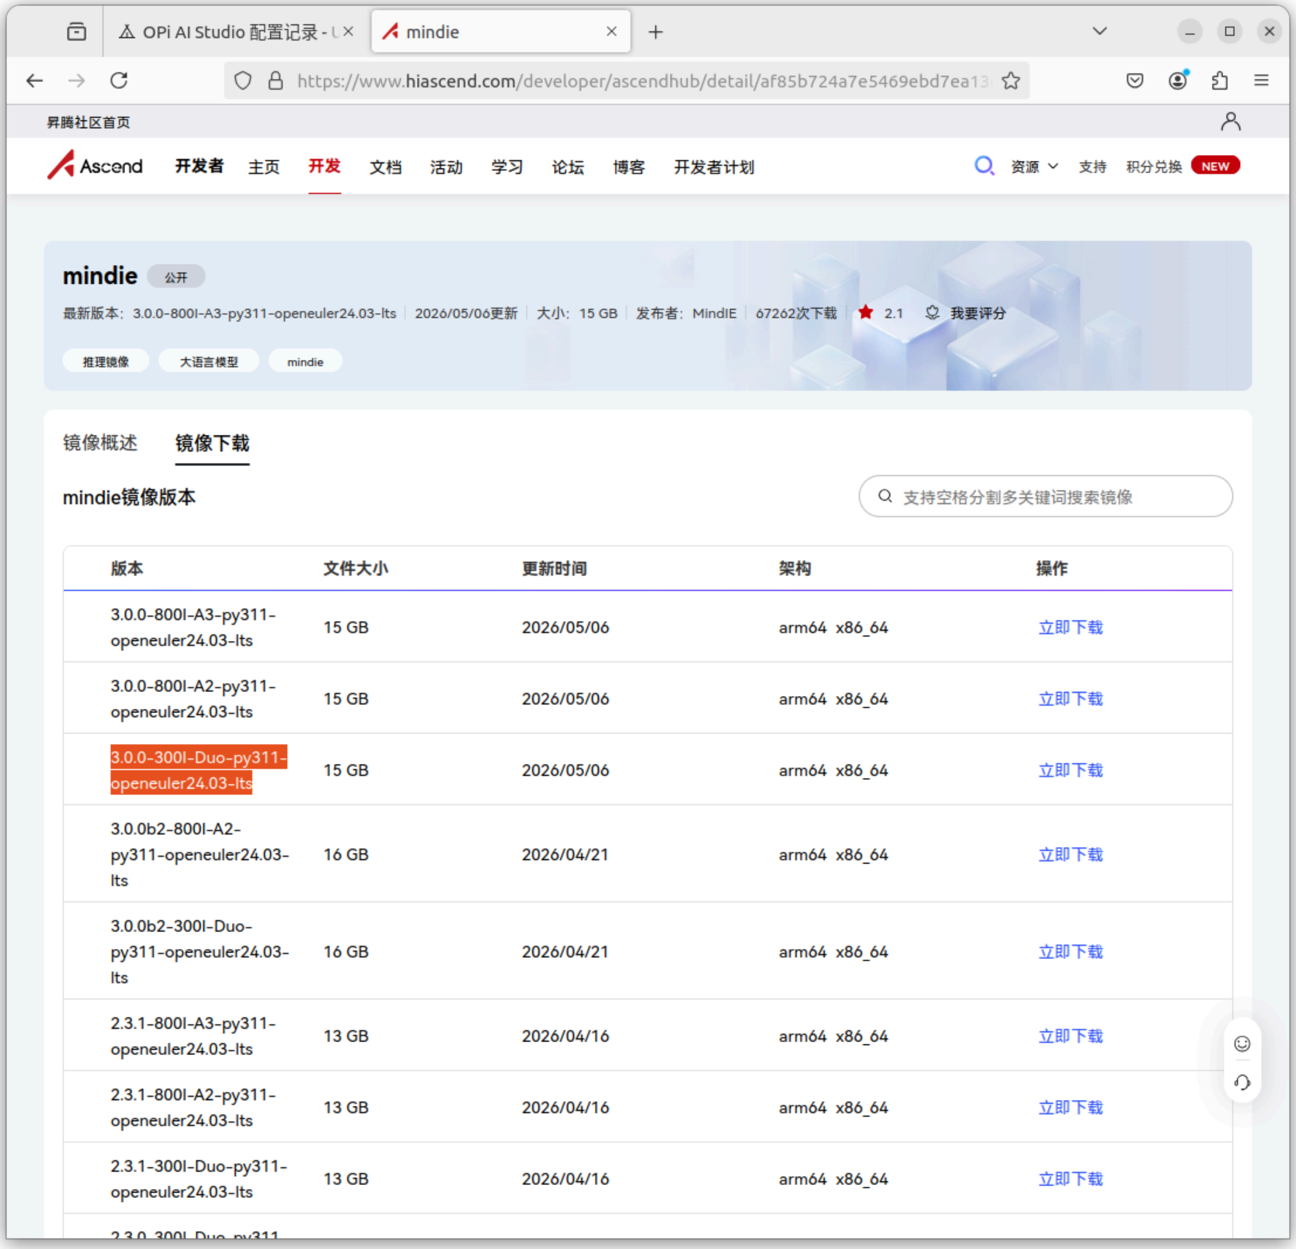
OPi AI Studio 配置记录
mindie
https://www.hiascend.com/developer/ascendhub/detail/af85b724a7e5469ebd7ea13
昇腾社区首页
Ascend
开发者
主页
开发
文档
活动
学习
论坛
博客
开发者计划
资源
支持
积分兑换
NEW
mindie
公开
最新版本：3.0.0-800I-A3-py311-openeuler24.03-lts | 2026/05/06更新 | 大小：15 GB | 发布者：MindIE | 67262次下载 | 2.1 | 我要评分
推理镜像
大语言模型
mindie
镜像概述
镜像下载
mindie镜像版本
支持空格分割多关键词搜索镜像
版本 | 文件大小 | 更新时间 | 架构 | 操作
3.0.0-800I-A3-py311-openeuler24.03-lts | 15 GB | 2026/05/06 | arm64 x86_64 | 立即下载
3.0.0-800I-A2-py311-openeuler24.03-lts | 15 GB | 2026/05/06 | arm64 x86_64 | 立即下载
3.0.0-300I-Duo-py311-openeuler24.03-lts | 15 GB | 2026/05/06 | arm64 x86_64 | 立即下载
3.0.0b2-800I-A2-py311-openeuler24.03-lts | 16 GB | 2026/04/21 | arm64 x86_64 | 立即下载
3.0.0b2-300I-Duo-py311-openeuler24.03-lts | 16 GB | 2026/04/21 | arm64 x86_64 | 立即下载
2.3.1-800I-A3-py311-openeuler24.03-lts | 13 GB | 2026/04/16 | arm64 x86_64 | 立即下载
2.3.1-800I-A2-py311-openeuler24.03-lts | 13 GB | 2026/04/16 | arm64 x86_64 | 立即下载
2.3.1-300I-Duo-py311-openeuler24.03-lts | 13 GB | 2026/04/16 | arm64 x86_64 | 立即下载

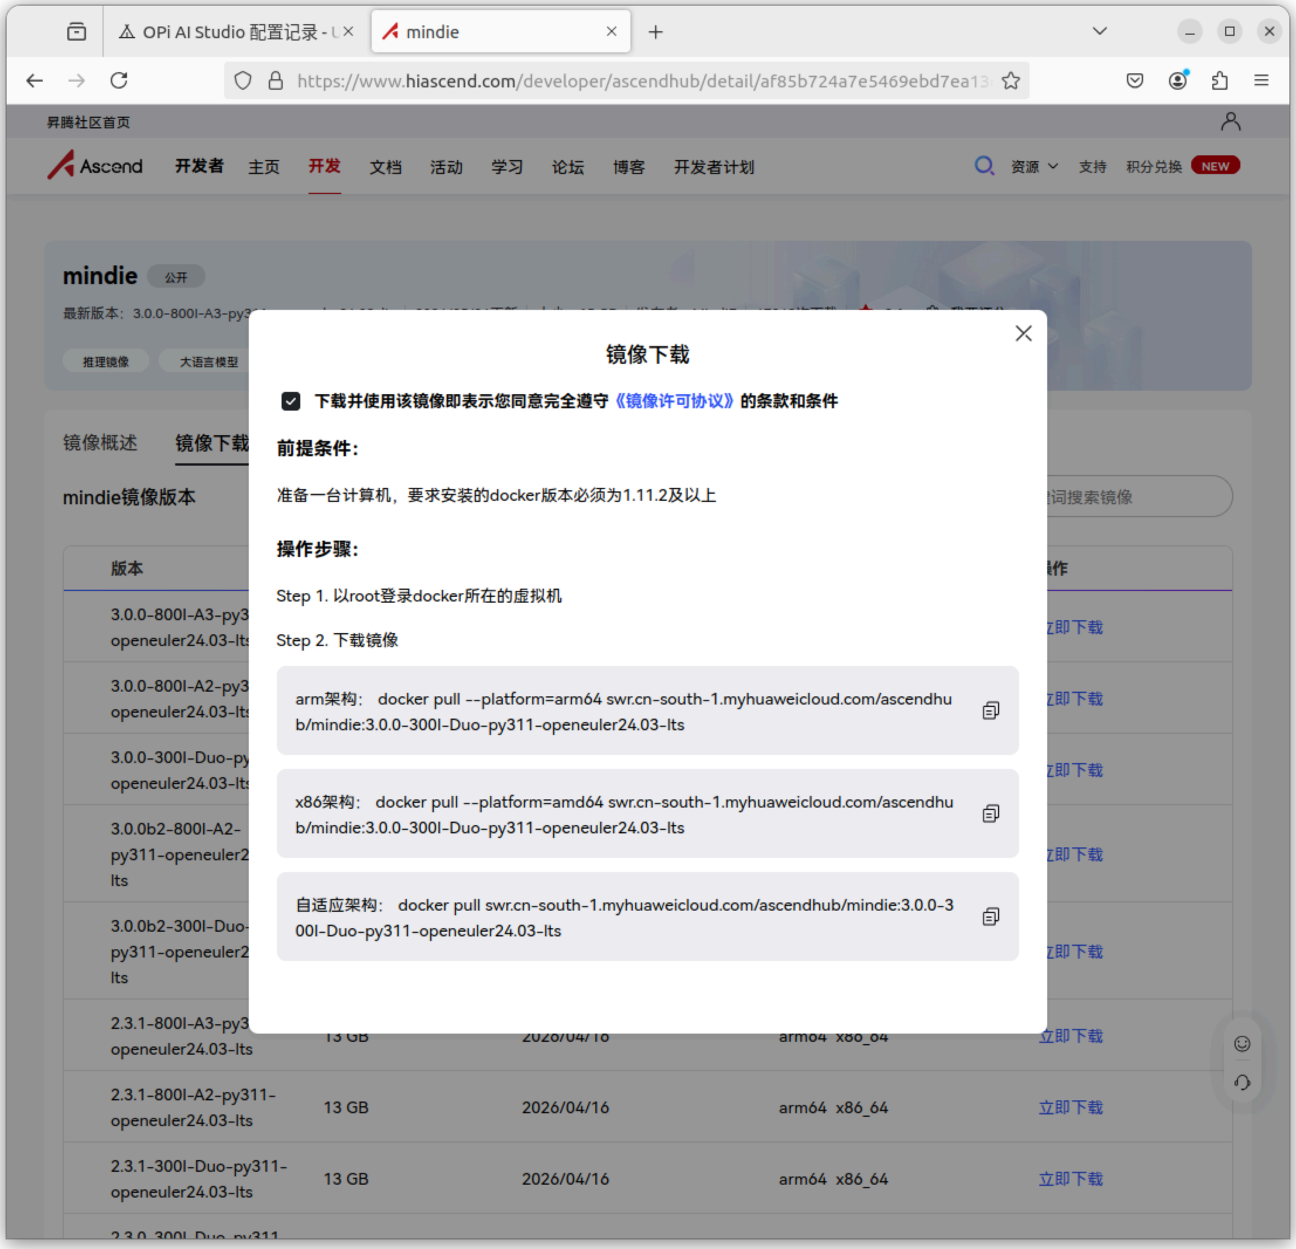
OPi AI Studio 配置记录
mindie
https://www.hiascend.com/developer/ascendhub/detail/af85b724a7e5469ebd7ea13
昇腾社区首页
Ascend 开发者 主页 开发 文档 活动 学习 论坛 博客 开发者计划
资源 支持 积分兑换 NEW
mindie 公开
推理镜像 大语言模型
镜像概述 镜像下载
mindie镜像版本
版本
镜像下载
下载并使用该镜像即表示您同意完全遵守《镜像许可协议》的条款和条件
前提条件：
准备一台计算机，要求安装的docker版本必须为1.11.2及以上
操作步骤：
Step 1. 以root登录docker所在的虚拟机
Step 2. 下载镜像
arm架构： docker pull --platform=arm64 swr.cn-south-1.myhuaweicloud.com/ascendhub/mindie:3.0.0-300I-Duo-py311-openeuler24.03-lts
x86架构： docker pull --platform=amd64 swr.cn-south-1.myhuaweicloud.com/ascendhub/mindie:3.0.0-300I-Duo-py311-openeuler24.03-lts
自适应架构： docker pull swr.cn-south-1.myhuaweicloud.com/ascendhub/mindie:3.0.0-300I-Duo-py311-openeuler24.03-lts
2.3.1-800I-A2-py311-openeuler24.03-lts 13 GB 2026/04/16 arm64 x86_64 立即下载
2.3.1-300I-Duo-py311-openeuler24.03-lts 13 GB 2026/04/16 arm64 x86_64 立即下载

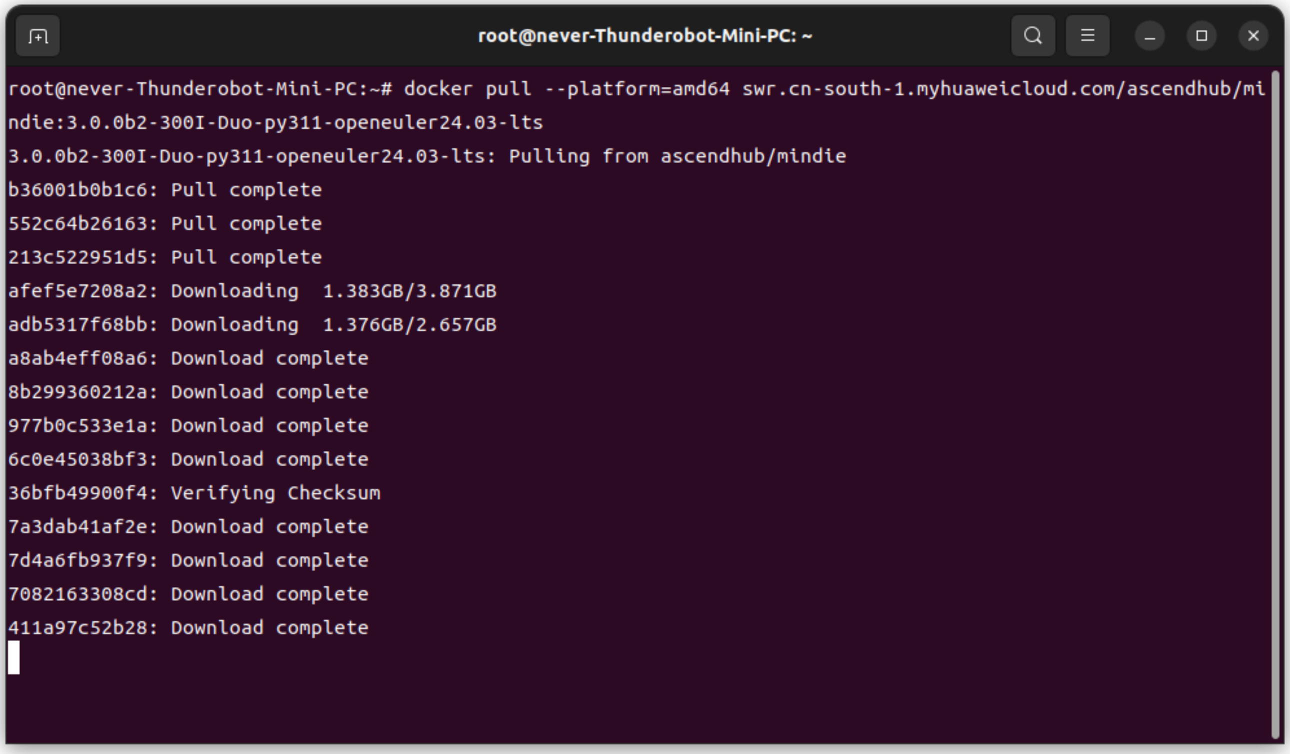

查看本地镜像列表:

```
docker images
```

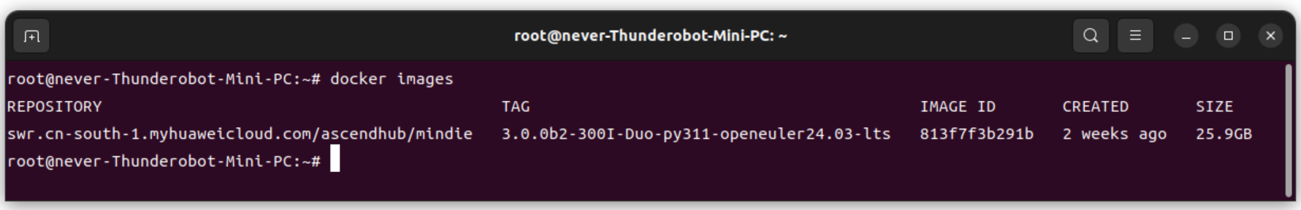

3) 编写并执行容器启动脚本

```
vim start_docker.sh
```

新建 `start_docker.sh`:
输入以下内容

```bash
IMAGE_ID=$1
NAME=${2:-mindie}

if [ -z "$IMAGE_ID" ]; then
    echo "usage: $0 <IMAGE_ID> [CONTAINER_NAME]"
    exit 1
fi

docker run --name "$NAME" -it -d --net=host --shm-size=500g \
    --privileged=true \
    -w /usr/local/Ascend \
    --device=/dev/davinci_manager \
    --device=/dev/hist_hdc \
    --device=/dev/devmm_svm \
    --entrypoint=bash \
    -v /models:/models \
    -v /data:/data \
    -v /usr/local/Ascend/driver:/usr/local/Ascend/driver \
    -v /usr/local/dcmt:/usr/local/dcmt \
    -v /usr/local/bin/npu-smi:/usr/local/bin/npu-smi \
    -v /usr/local/sbin:/usr/local/sbin \
    -v /home:/home \
    -v /tmp:/tmp \
    -v /usr/share/zoneinfo/Asia/Shanghai:/etc/localtime \
    -e http_proxy=$http_proxy \
    -e https_proxy=$https_proxy \
    -e "PATH=/usr/local/python3.11.10/bin:$PATH" \
    "$IMAGE_ID"
```

```
root@never-Thunderobot-Mini-PC: ~

IMAGE_ID=$1
NAME=${2:-mindie}

if [ -z "$IMAGE_ID" ]; then
    echo "usage: $0 <IMAGE_ID> [CONTAINER_NAME]"
    exit 1
fi

docker run --name "$NAME" -it -d --net=host --shm-size=500g \
    --privileged=true \
    -w /usr/local/Ascend \
    --device=/dev/davinci_manager \
    --device=/dev/hist_hdc \
    --device=/dev/devmm_svm \
    --entrypoint=bash \
    -v /models:/models \
    -v /data:/data \
    -v /usr/local/Ascend/driver:/usr/local/Ascend/driver \
    -v /usr/local/dcmt:/usr/local/dcmt \
    -v /usr/local/bin/npu-smi:/usr/local/bin/npu-smi \
    -v /usr/local/sbin:/usr/local/sbin \
    -v /home:/home \
    -v /tmp:/tmp \
    -v /usr/share/zoneinfo/Asia/Shanghai:/etc/localtime \
    -e http_proxy=$http_proxy \
    -e https_proxy=$https_proxy \
    -e "PATH=/usr/local/python3.11.10/bin:$PATH" \
    "$IMAGE_ID"
                                                    28,13         全部
```

赋予权限并启动:

```bash
chmod +x start_docker.sh
./start_docker.sh IMAGE_ID CONTAINER_NAME
```

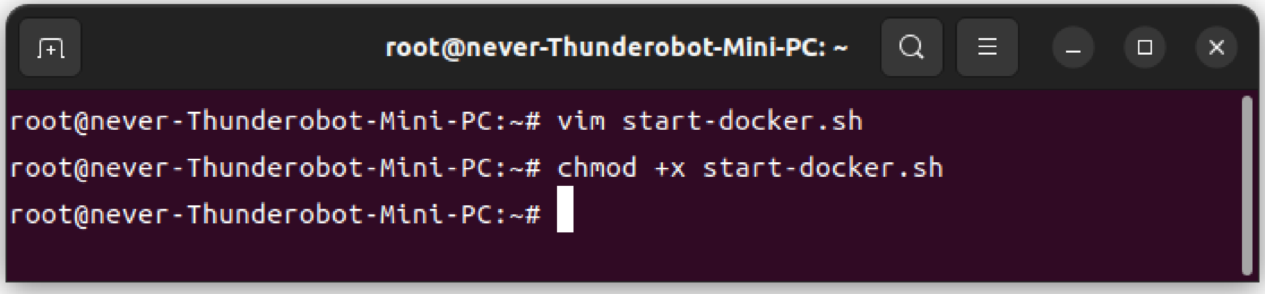

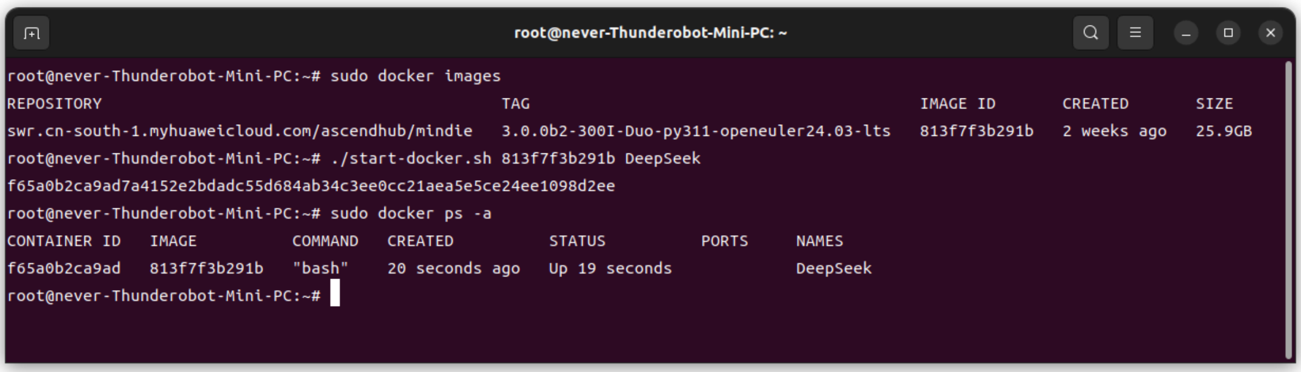

七、下载模型（DeepSeek-R1-Distill-Qwen-14B）

安装 git-lfs：

```bash
sudo apt install -y git-lfs
```

切换至/models目录：

```
cd /models
```

模型地址：https://huggingface.co/deepseek-ai/DeepSeek-R1-Distill-Qwen-14B

国内网络建议使用镜像：

```
git clone --depth=1 https://modelers.cn/XLRJ/DeepSeek-R1-Distill-Qwen-14B
```

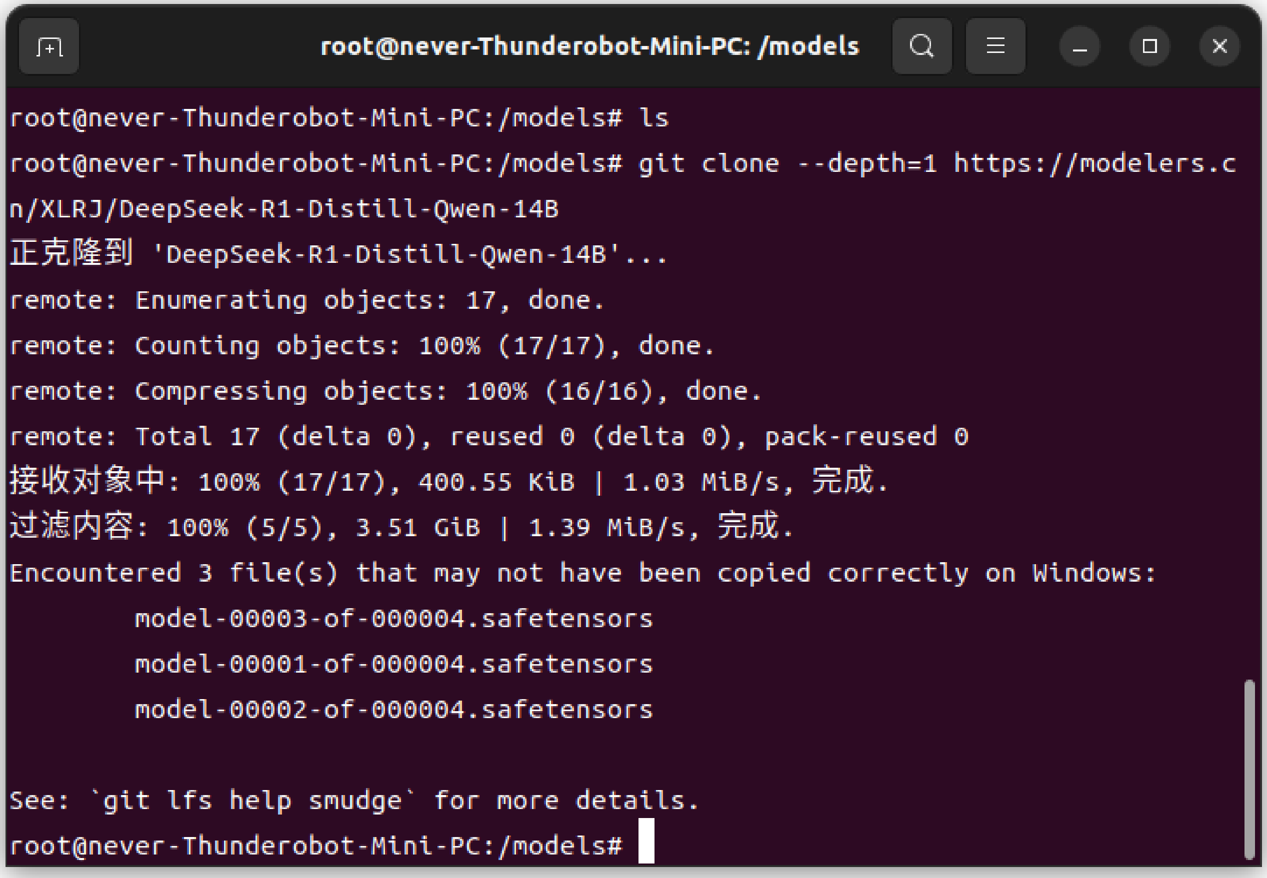

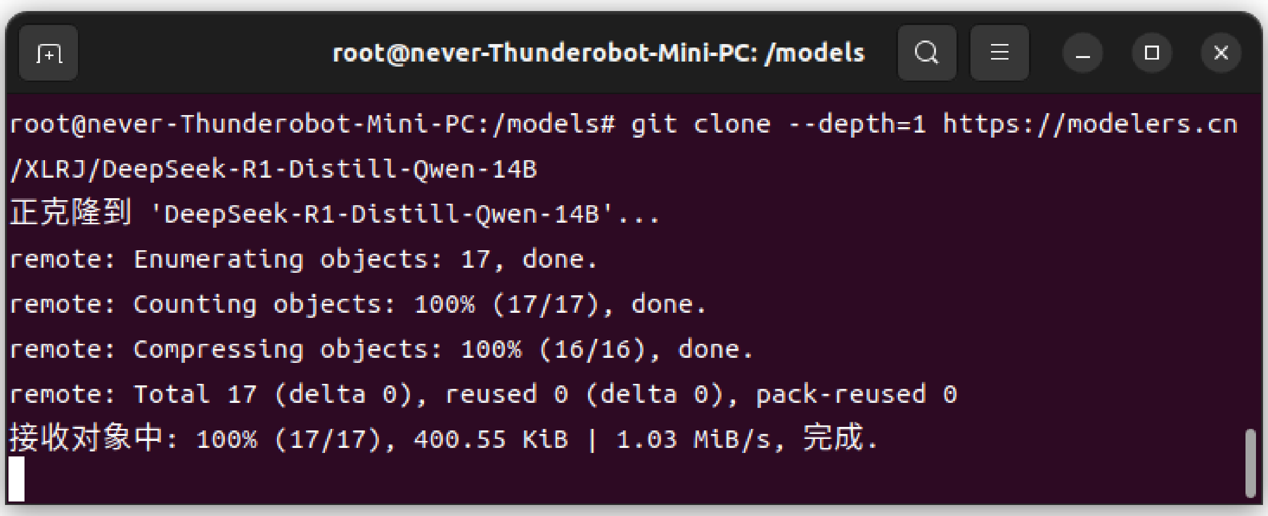

下载过程较长，可在模型目录观察大小变化：

```
du -sh
```

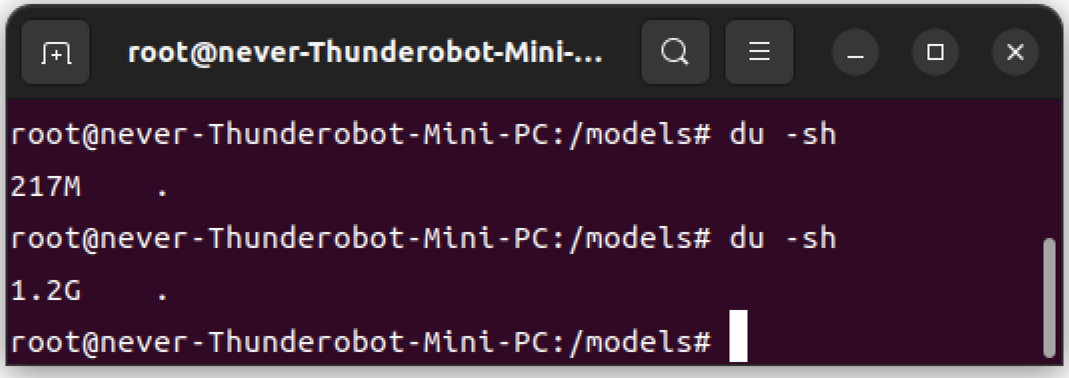

当然也可以通过watch命令持续监控：

```
watch -n 1 du -sh
```

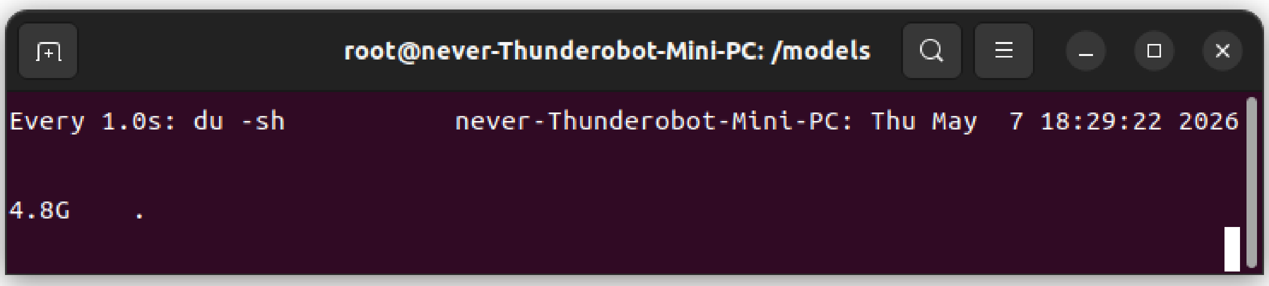

八、模型配置、推理验证与服务启动

下面把后续实操整理成一条更顺的链路：先把模型配置和权限处理好，再做一次本地推理验证，最后启动 MindIE 服务并用 `curl` 复核接口。

1) 模型配置调整（float16）

进入模型目录：

```
cd /models/DeepSeek-R1-Distill-Qwen-14B/
```

编辑配置文件：

```
vim config.json
```

确认或修改 `torch_dtype` 为：

```
"torch_dtype": "float16"
```

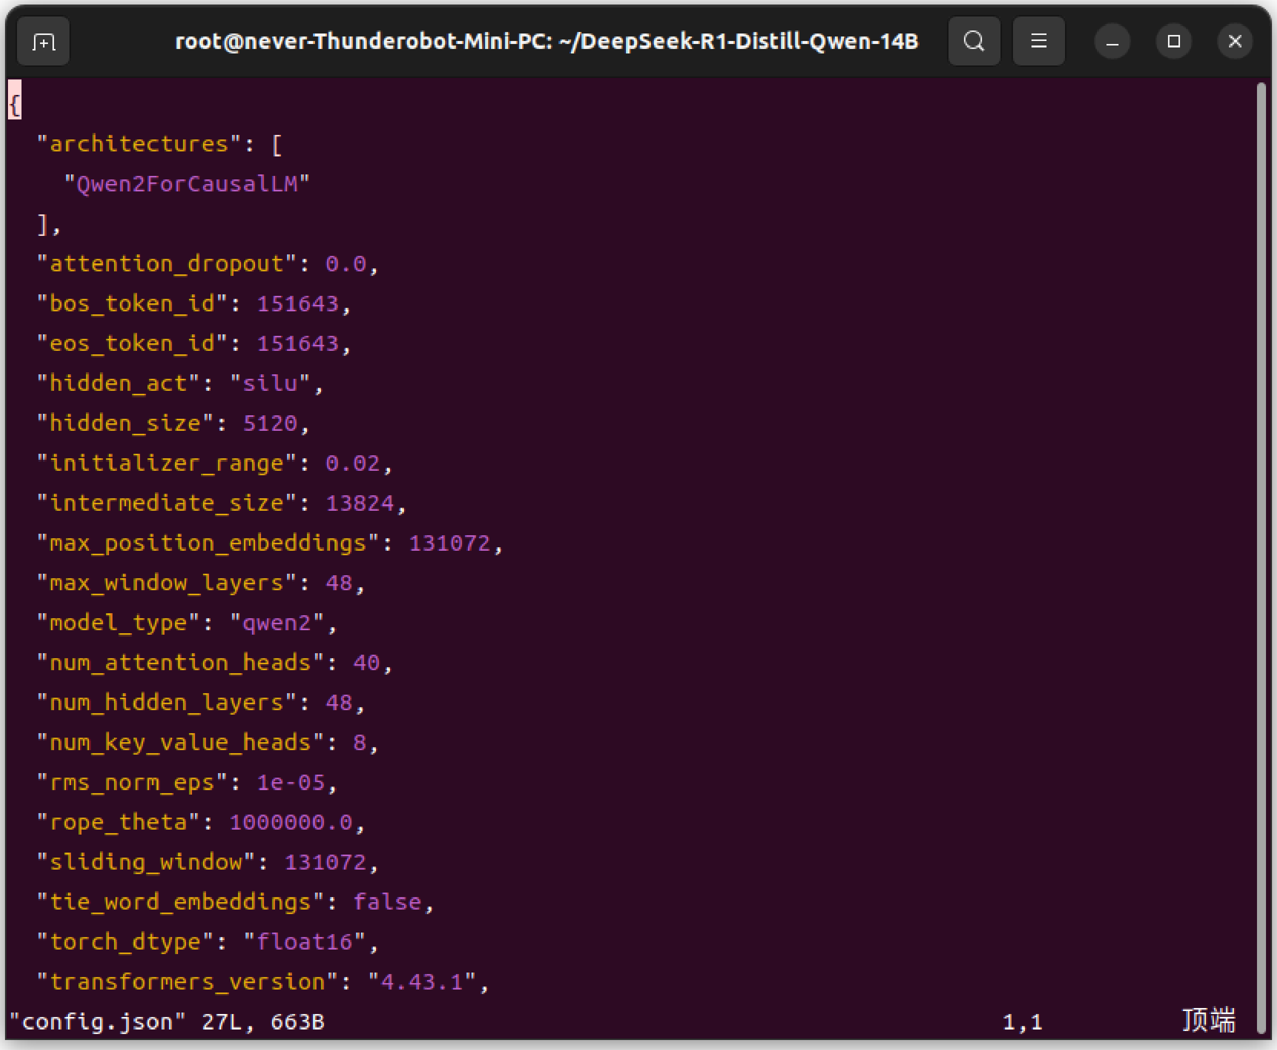

```
root@never-Thunderobot-Mini-PC: ~/DeepSeek-R1-Distill-Qwen-14B
{
  "architectures": [
    "Qwen2ForCausalLM"
  ],
  "attention_dropout": 0.0,
  "bos_token_id": 151643,
  "eos_token_id": 151643,
  "hidden_act": "silu",
  "hidden_size": 5120,
  "initializer_range": 0.02,
  "intermediate_size": 13824,
  "max_position_embeddings": 131072,
  "max_window_layers": 48,
  "model_type": "qwen2",
  "num_attention_heads": 40,
  "num_hidden_layers": 48,
  "num_key_value_heads": 8,
  "rms_norm_eps": 1e-05,
  "rope_theta": 1000000.0,
  "sliding_window": 131072,
  "tie_word_embeddings": false,
  "torch_dtype": "float16",
  "transformers_version": "4.43.1",
"config.json" 27L, 663B                                  1,1           顶端
```

建议执行一次快速校验，确保 JSON 结构未被破坏：

```
python3 -m json.tool config.json >/dev/null && echo "config.json is valid"
```

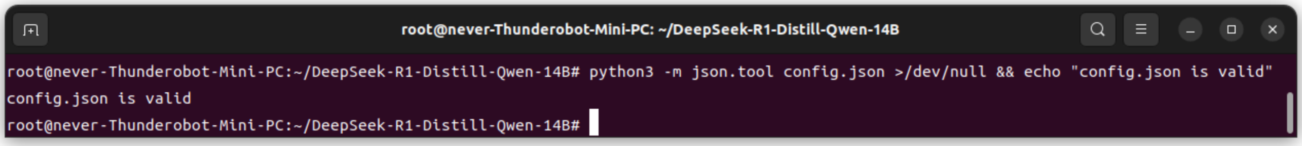

2) 调整模型权限与所有者

在模型目录执行：

```
sudo chmod 640 config.json
cd ..
sudo chown -R root:root /models/DeepSeek-R1-Distill-Qwen-14B/
```

校验权限：

```
ls -l /models/DeepSeek-R1-Distill-Qwen-14B/config.json
ls -ld /models/DeepSeek-R1-Distill-Qwen-14B
```

目标是保证配置文件权限收敛、目录所有者统一，减少容器内运行时的权限歧义。

3) 进入容器并执行一次本地推理

启动并进入容器（`NAME` 为你自定义的容器名）：

```
docker start NAME
docker exec -it NAME bash
```

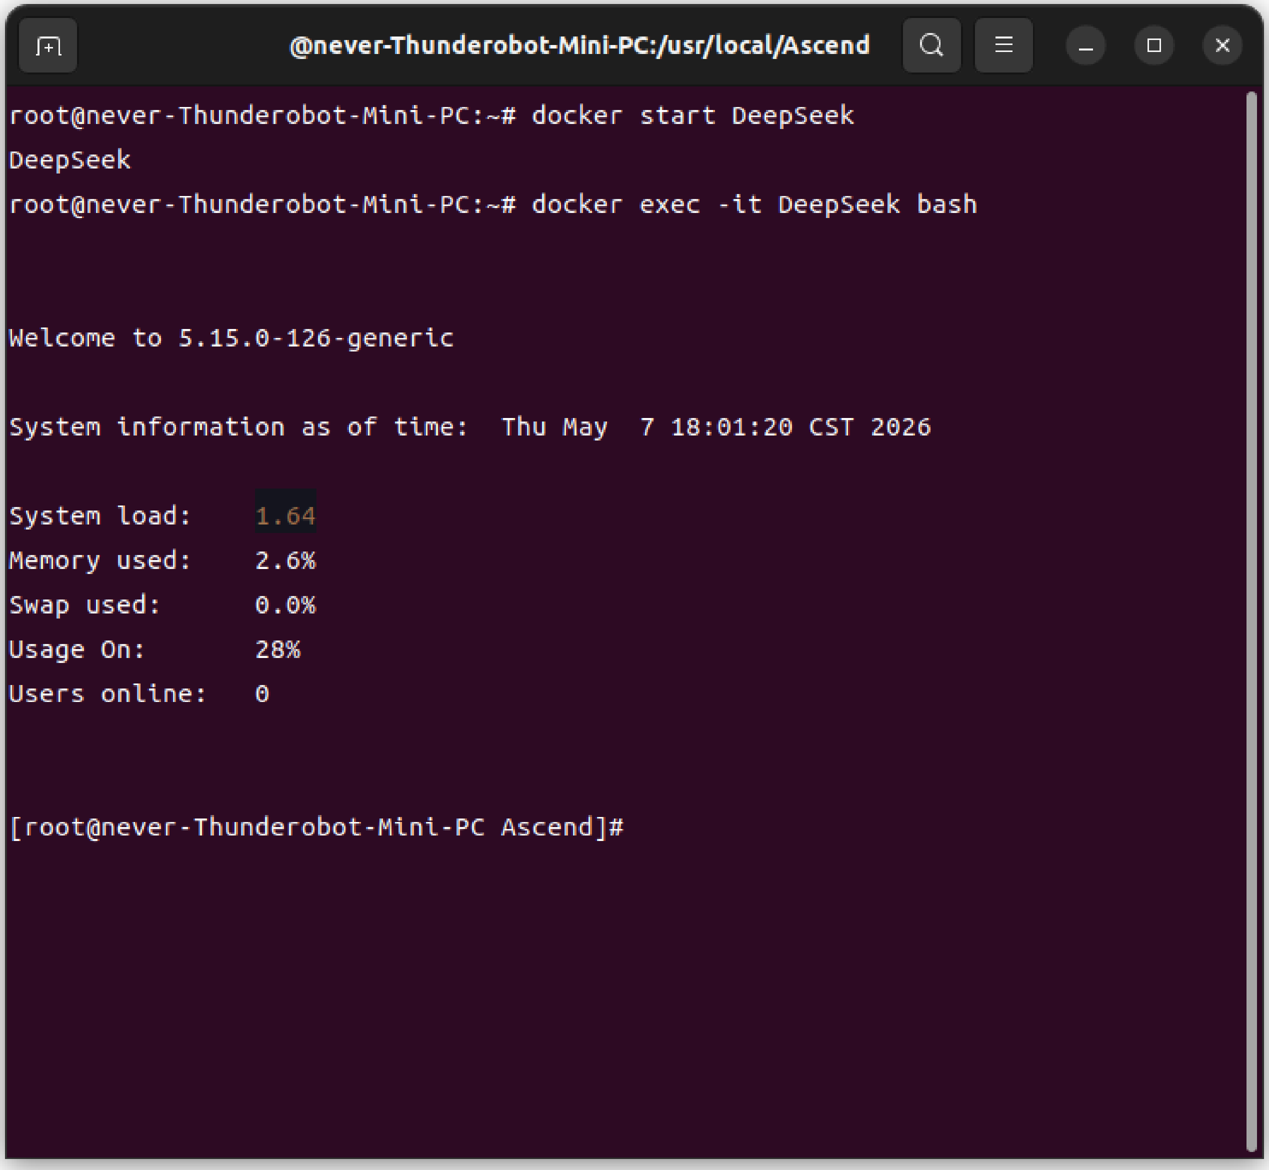

进入工作目录：

```
cd atb-models/
```

先执行环境变量配置：

```
export MINDIE_LOG_TO_STDOUT=1
```

再执行推理命令：

```
torchrun --nproc_per_node 1 --master_port 20037 -m examples.run_pa --model_path /models/De
```

另开一个终端观察 NPU 使用情况：

```
watch -n 0.2 npu-smi info
```

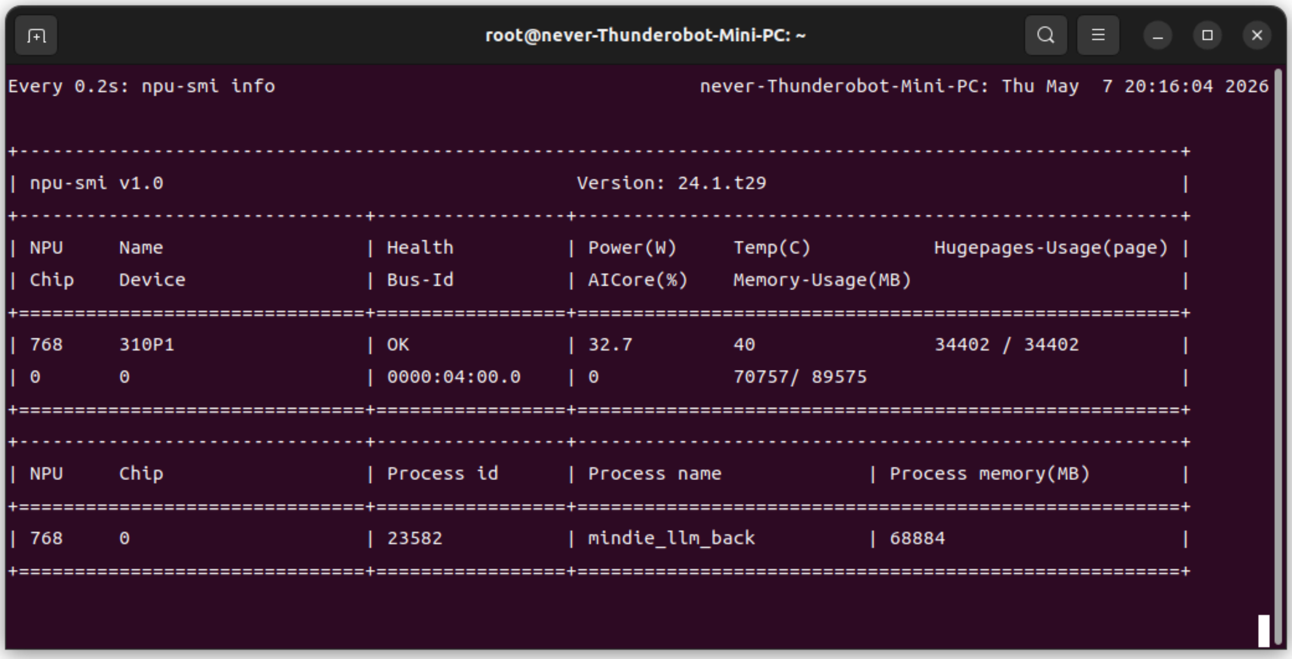

如果推理期间 NPU 利用率和显存占用有明显变化，说明任务已正确落到设备侧。加载进度跑到 100% 后，通常就会继续进入模型推理阶段：

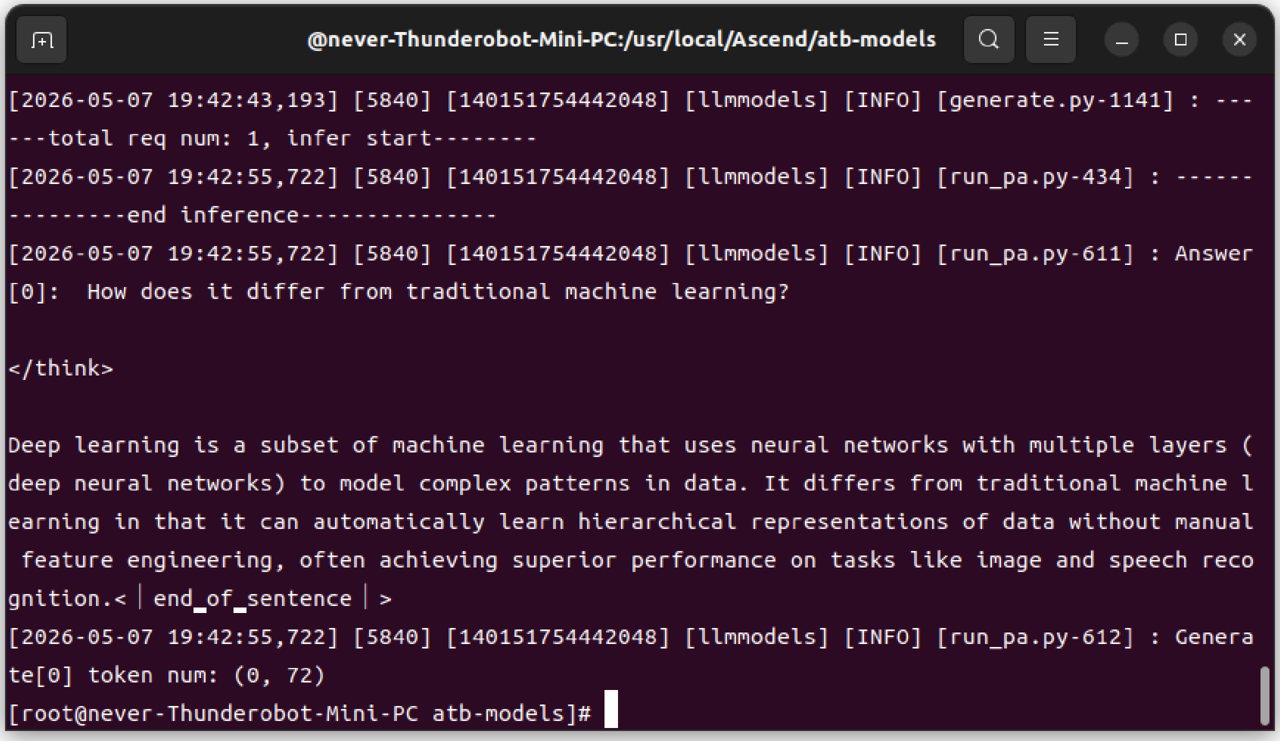

Tips: 注意！如果不进行**环境变量配置**，执行推理命令时将会加载至100%后直接异常退出：

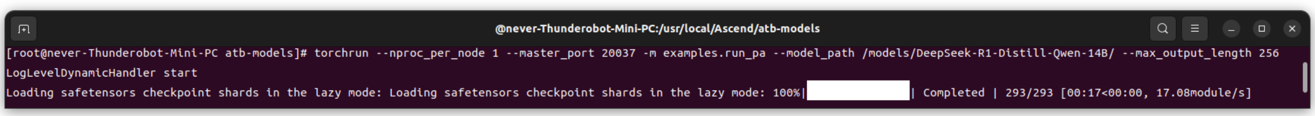

4) 启动 mindie-service（服务化）

在容器内进入目录：

```
cd ../mindie/latest/mindie-service/
```

编辑配置：

```
vim conf/config.json
```

将关键字段改为单卡 HTTP 场景：

```
"httpsEnabled": false,
"npuDeviceIds": [[0]],
"worldSize": 1,
"modelWeightPath": "/models/DeepSeek-R1-Distill-Qwen-14B/"
```

启动服务：

```
./mindieservice_daemon
```

报错：

```
./mindieservice_daemon: error while loading shared libraries: libtorch_cpu.so: cannot ope
```

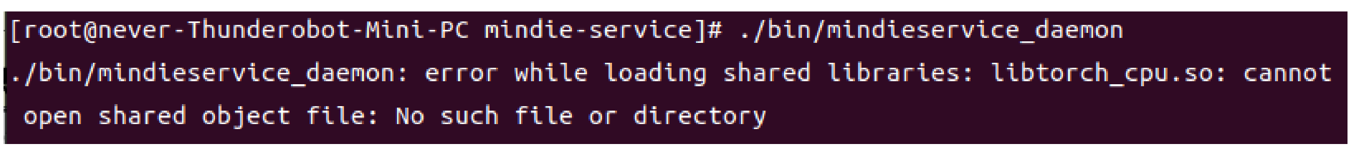

这类报错通常说明运行时环境变量还没补齐。先尝试激活下面这些环境：

```
# 配置CANN环境，默认安装在/usr/local目录下
source /usr/local/Ascend/ascend-tookit/set_env.sh
# 配置加速库环境
source /usr/local/Ascend/nnal/atb/set_env.sh
# 配置模型仓环境变量
source /usr/local/Ascend/atb-models/set_env.sh
source /usr/local/Ascend/mindie/atb/set_env.sh
```

再次启动后，若看到 `Daemon start success!`，说明服务已经正常拉起：

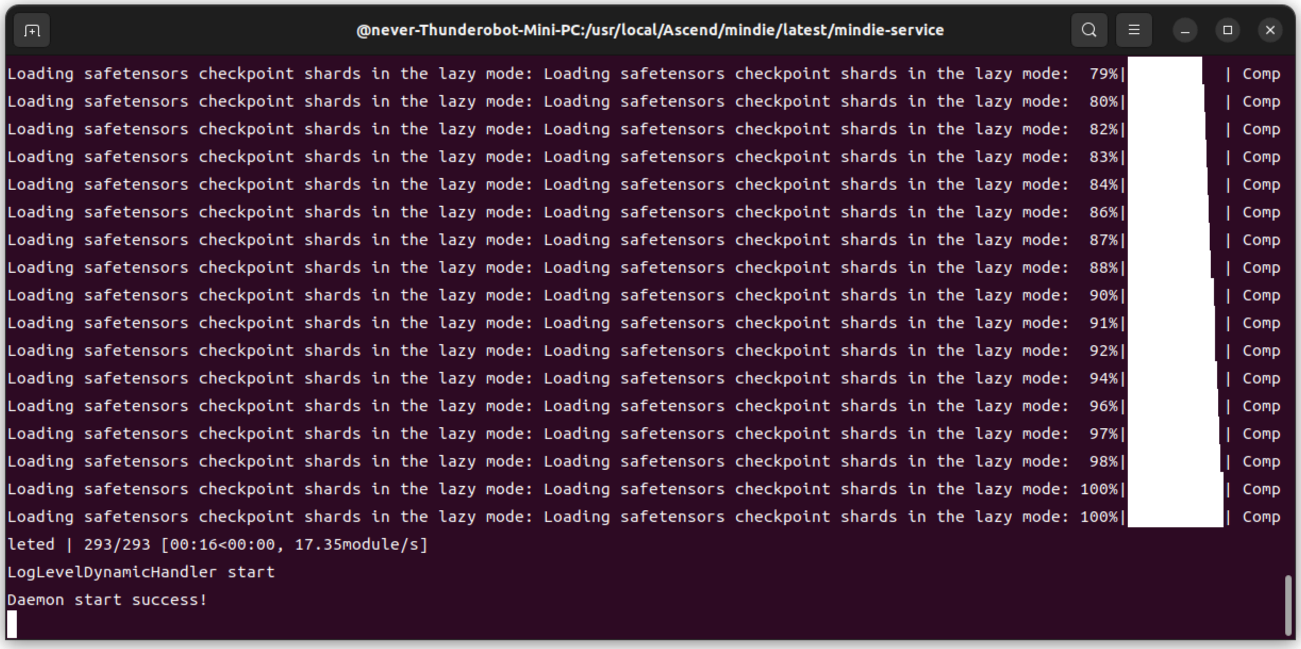

可能出现运存不足时，尝试增加交换分区：

```
sudo fallocate -l 64G /swapfile
sudo chmod 600 /swapfile
sudo mkswap /swapfile
sudo swapon /swapfile
```

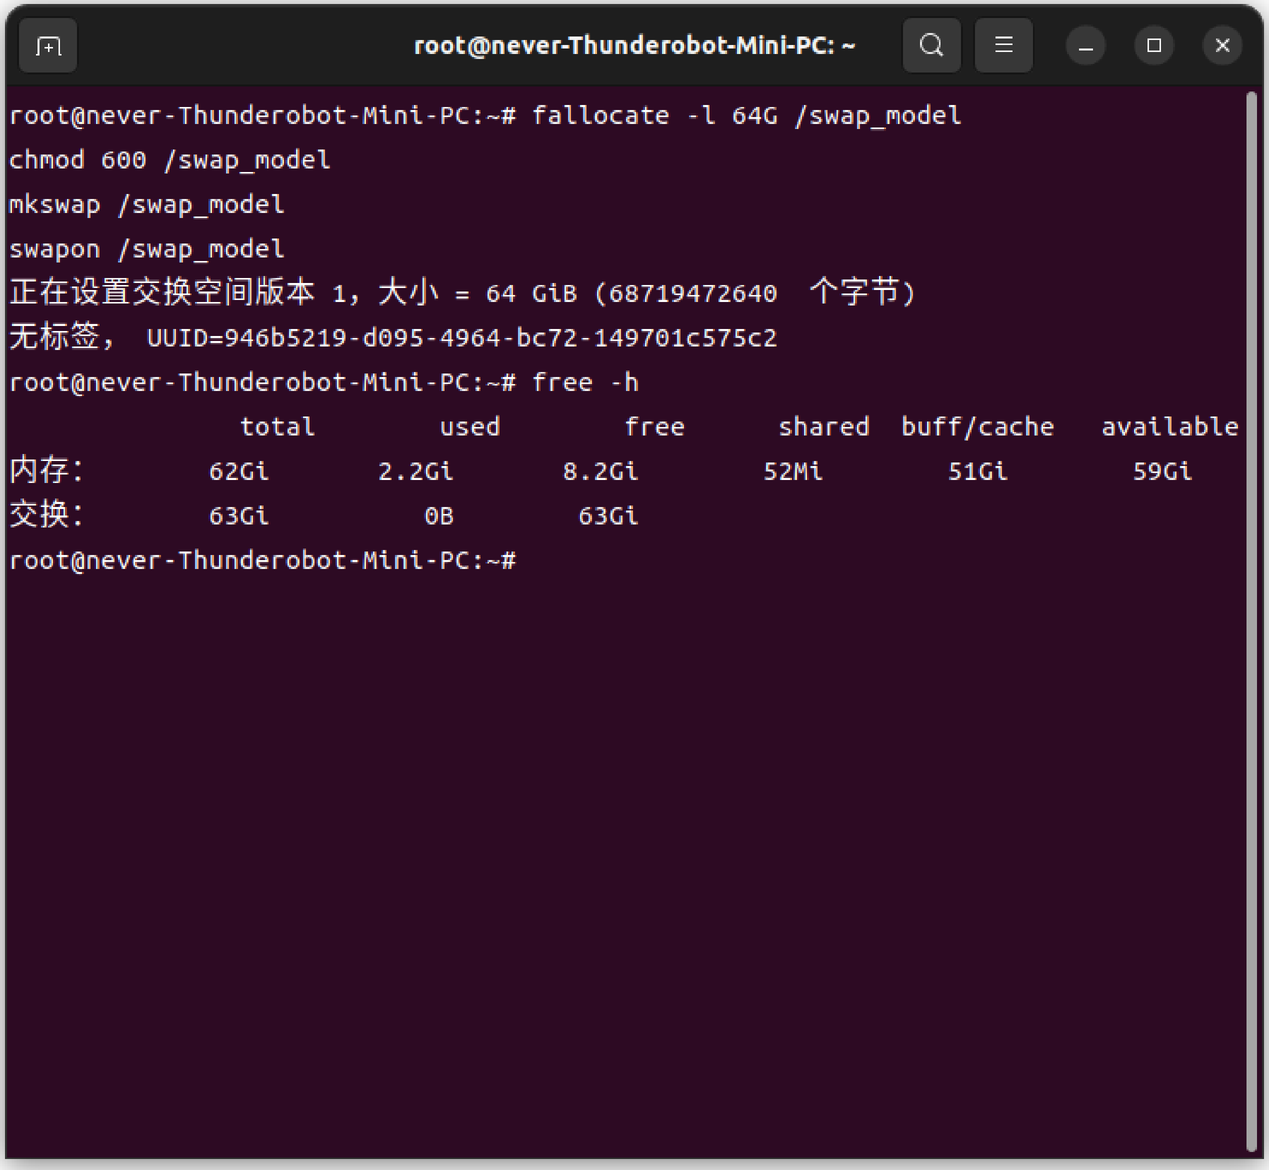

在运行结束时可以关闭交换分区：

```
sudo swapoff /swapfile
sudo rm /swapfile
```

5) 使用 curl 验证 HTTP 接口

MindIE 服务启动后，可以直接用 `curl` 调用 `generate` 接口做快速验证：

```
curl -w "\ntime_total=%{time_total}\n" \
    -H "Accept: application/json" \
    -H "Content-type: application/json" \
    -X POST -d '{"inputs":"Who are you?","stream":false}' \
    http://127.0.0.1:1025/generate
```

示例结果如下:

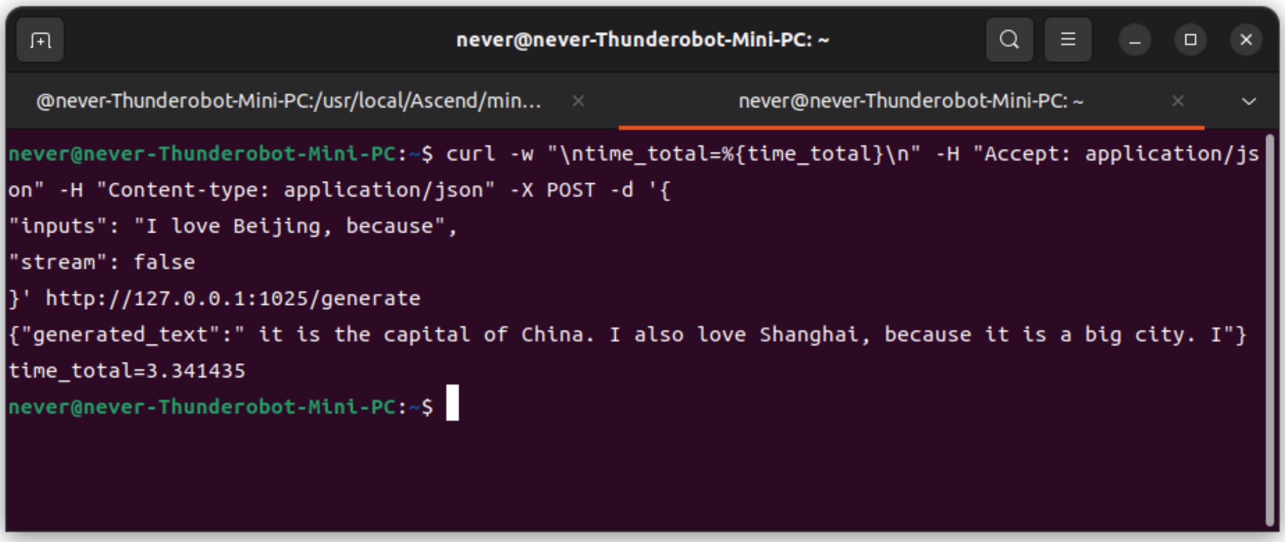

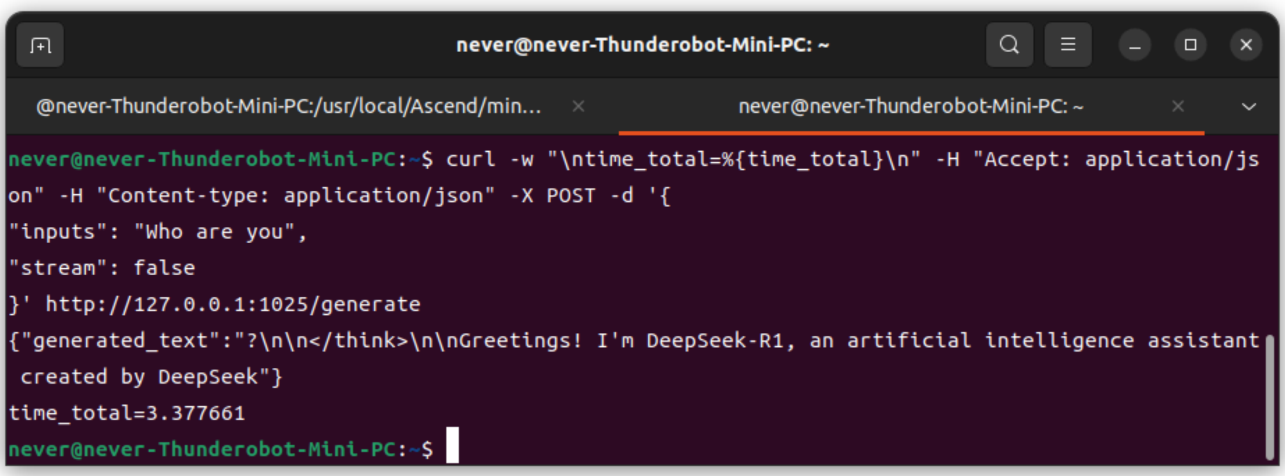

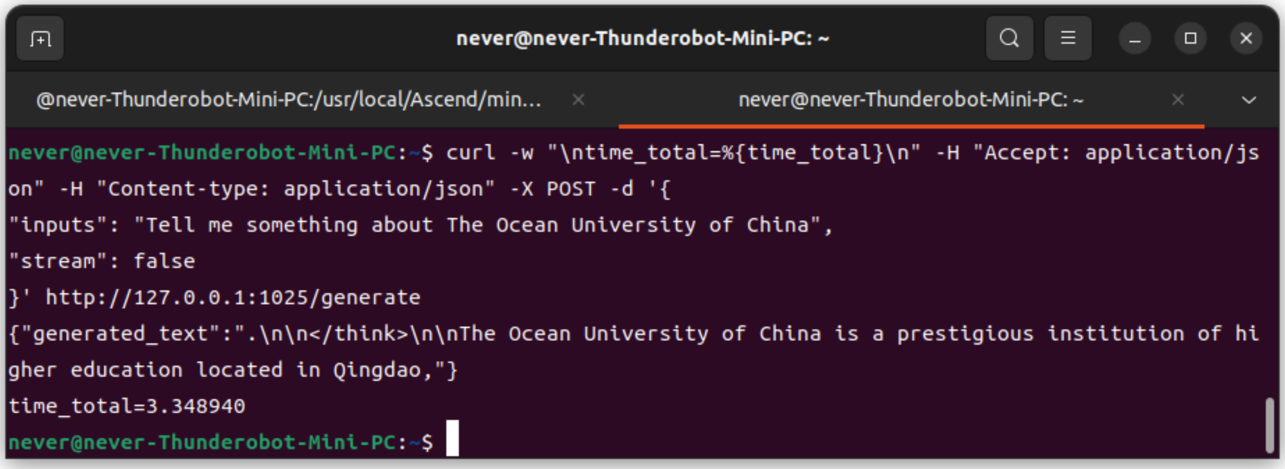

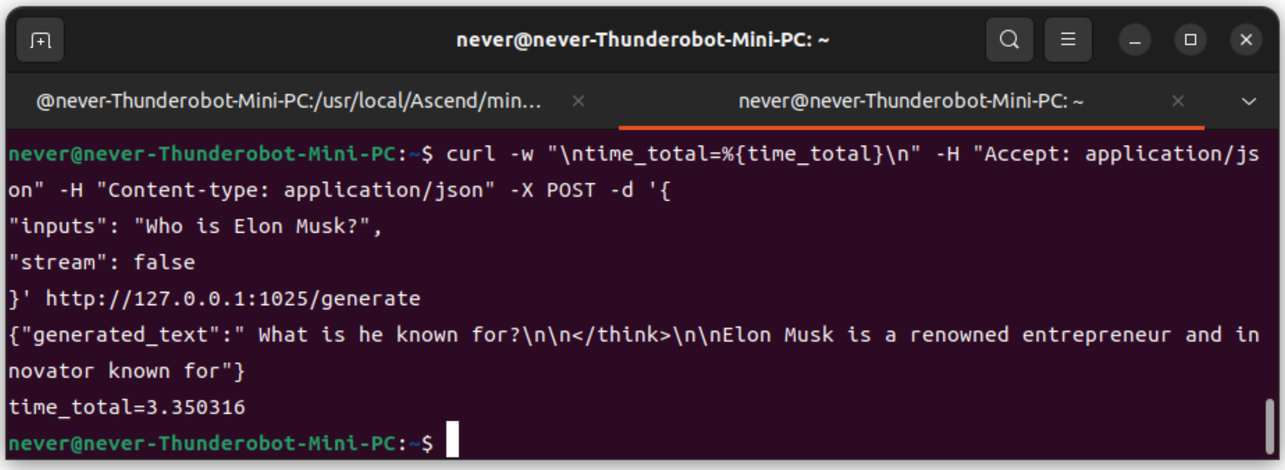

完成了最终接口部署的验证，至此整个 OPi AI Studio 在 Ubuntu 环境下的部署流程就算是完整走通了。

接下来将在此基础之上，进一步调试上下文长度、并发性能等参数，并且换上精度更高的模型进行调试，以实现更快、质量更高的推理能力，尽可能地释放OPi AI Studio的潜力。

同时，在这个基础上通过调用本地部署的模型接口的方式，开始养龙虾(OpenClaw / Hermes Agent)！